Trabalho de Machine Learning

Lucas de Almeida, RA: 1996762
Vinícius Augusto de Souza, RA: 1997530

O *dataset* escolhido para este trabalho foi o famoso dataset **Iris**, que pode ser acessado nesse link. Se trata de um conjunto de dados relativos a três espécies da flor Iris (Iris setosa, Iris virginica e Iris versicolor).

In [1]:
```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
```

Após importar as bibliotecas para auxiliar no projeto, foi necessário ler o arquivo '*iris.data*' que contém efetivamente os dados utilizados para treinar e testar o modelo.

Para cada coluna dos dados, atribuiu-se seus respectivos nomes:

- *sepal_lenght*: o comprimento da sépala;
- *sepal_width*: a largura da sépala;
- *petal_length*: o comprimento da pétala;
- *petal_width*: a largura da pétala;
- *class*: qual é sua espécie (Iris setosa, Iris virginica ou Iris versicolor).

In [2]:
```
df = pd.read_csv('iris.data')
```

In [3]:
```
attributes = ["sepal_length", "sepal_width", "petal_length", "petal_width", "class"]
df.columns = attributes
```

Abaixo pode-se observar parte do inicio e fim do conjunto de dados já com as colunas nomeadas.

In [4]:
```
df
```

Out[4]:

	sepal_length	sepal_width	petal_length	petal_width	class
0	4.9	3.0	1.4	0.2	Iris-setosa
1	4.7	3.2	1.3	0.2	Iris-setosa
2	4.6	3.1	1.5	0.2	Iris-setosa
3	5.0	3.6	1.4	0.2	Iris-setosa
4	5.4	3.9	1.7	0.4	Iris-setosa
...	...	...	...	...	...
144	6.7	3.0	5.2	2.3	Iris-virginica
145	6.3	2.5	5.0	1.9	Iris-virginica
146	6.5	3.0	5.2	2.0	Iris-virginica
147	6.2	3.4	5.4	2.3	Iris-virginica
148	5.9	3.0	5.1	1.8	Iris-virginica

149 rows × 5 columns

Foi feita em seguida a plotagem dos gráficos da matriz de dispersão entre os parâmetros das amostras do dataset, tendo na diagonal principal o histograma dos parâmetros e no restante da matriz a dispersão dos dados. O resultado pode ser visto na figura abaixo.

In [5]:
```
fig, axs = plt.subplots(4,4,figsize=(12,12))
plt.subplots_adjust(wspace=0, hspace=0)
axs[3,0].set(xlabel="sepal_length")
axs[3,1].set(xlabel="sepal_width")
axs[3,2].set(xlabel="petal_length")
axs[3,3].set(xlabel="petal_width")
axs[0,0].set(ylabel="sepal_length")
axs[1,0].set(ylabel="sepal_width")
axs[2,0].set(ylabel="petal_length")
axs[3,0].set(ylabel="petal_width")
for j in range(0,4):
    for i in range(0,4):
        if(i == j):
            axs[i,j].bar(df.iloc[:, j],df.iloc[:,i])
        else:
            axs[i,j].scatter(df.iloc[:,j], df.iloc[:, i])
for ax in axs.flat:
    ax.label_outer()
```

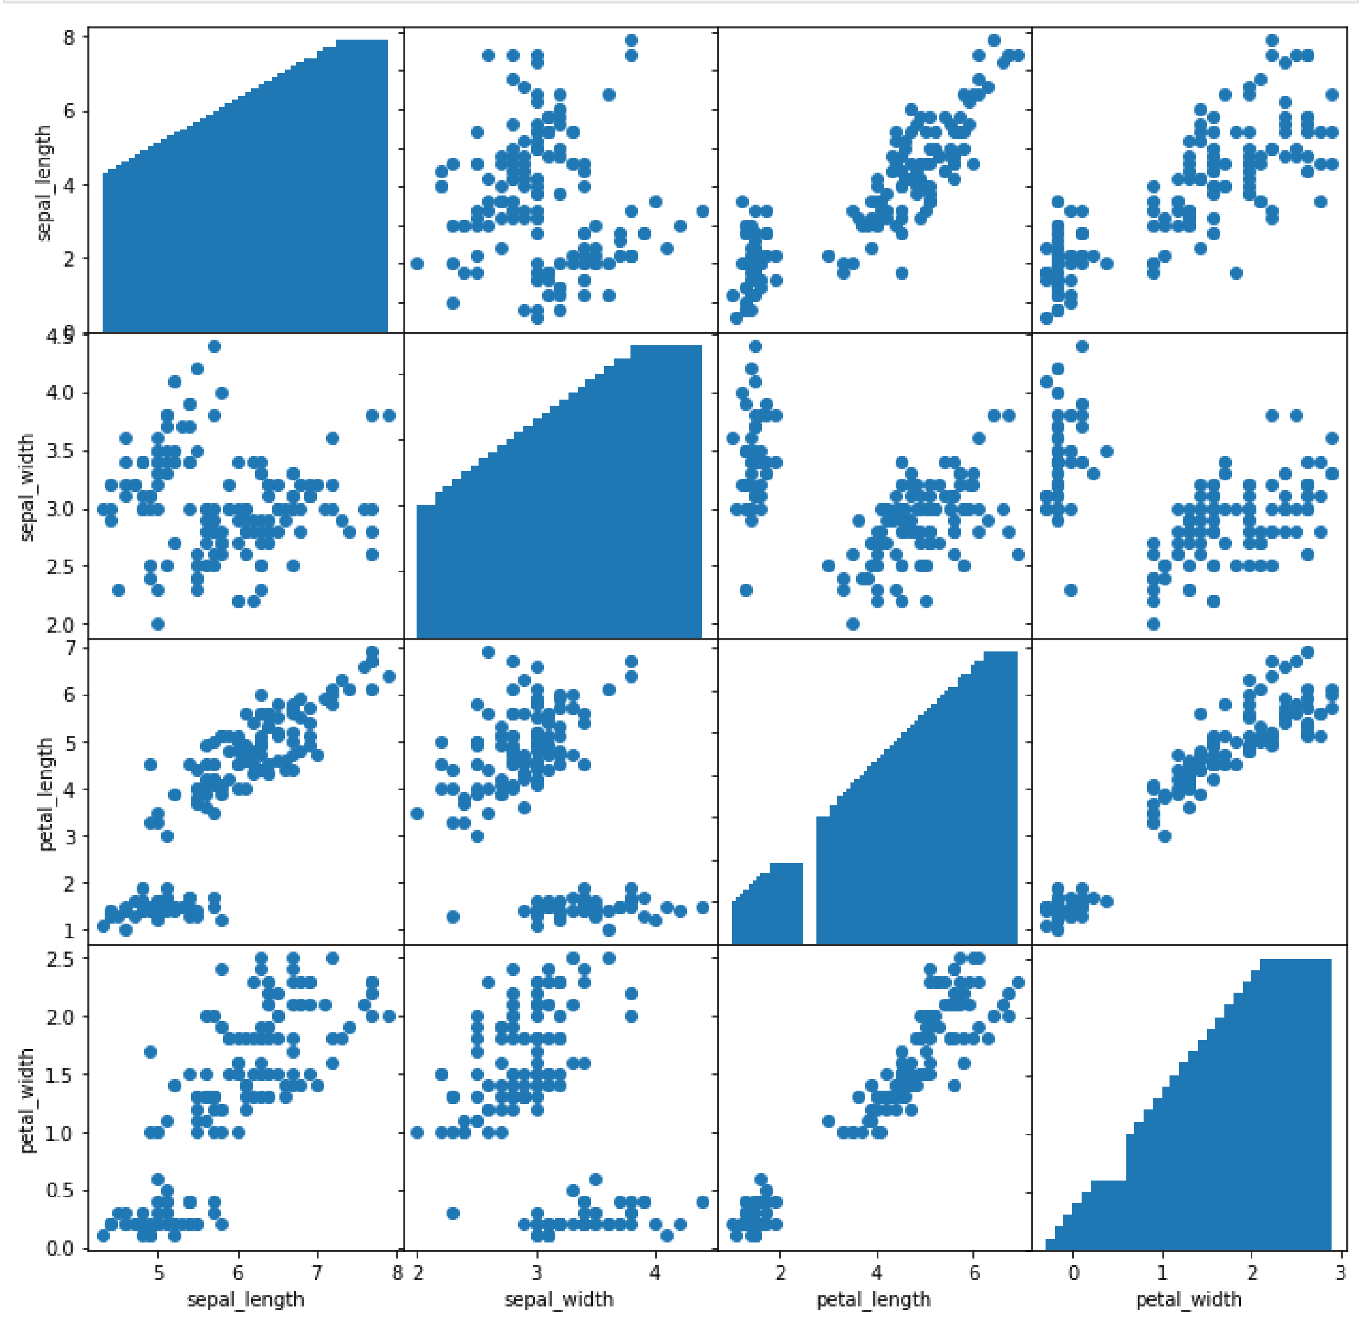

Em seguida, foi feito o boxplot desse dataset.

BoxPlot

É um método para representar graficamente grupos de dados numéricos por meio de seus quartis. Os boxplot também podem ter linhas que se estendem das caixas indicando a variabilidade fora dos quartis superior e inferior

In [6]:
```
plt.figure(figsize = (8, 8))
df.boxplot()
```

Out[6]:
```
<AxesSubplot:>
```

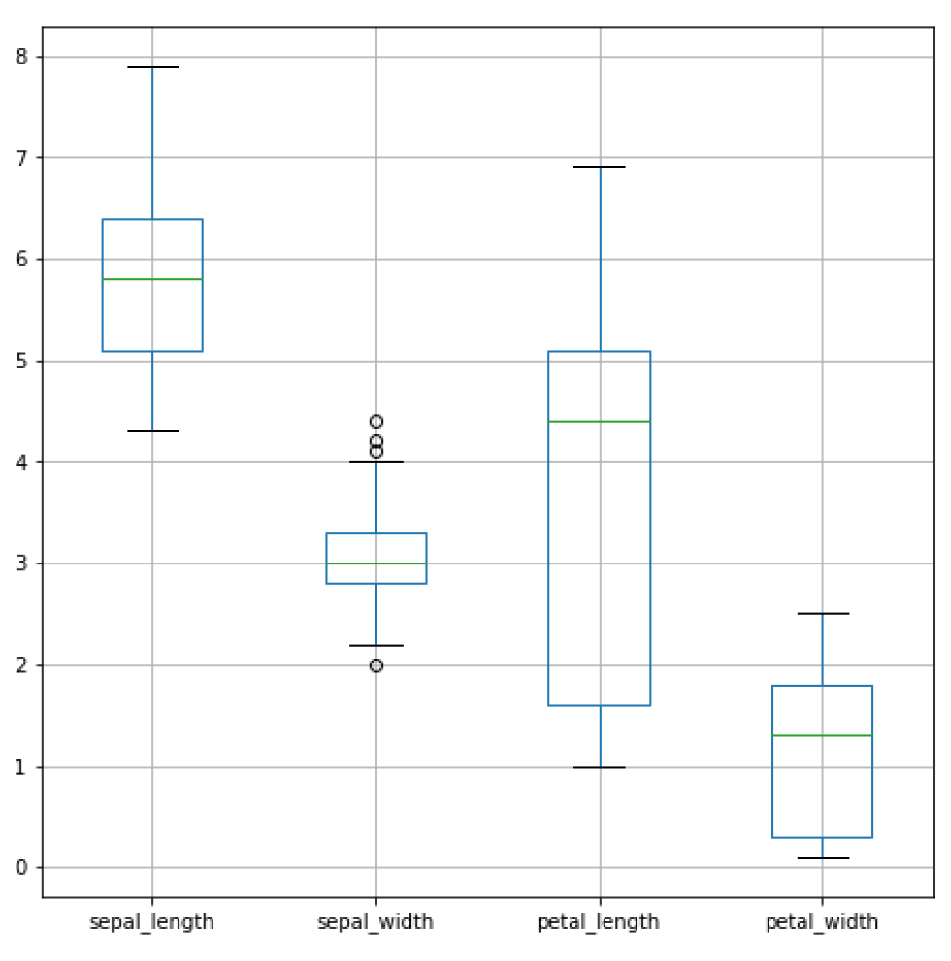

E então, iniciou-se o processo de treinamento do modelo de machine learning escolhido, que foi o modelo **Decision Tree**.

Os passos a seguir foram:

- Criar uma cópia da coluna "*class*" do conjunto de dados e armazenar na variável *y*;
- Criar uma cópia de todas as colunas do conjunto de dados, com exceção da coluna "*class*", e armazenar na variável *x*;
- Importar a função "*train_test_split*" da biblioteca "*sklearn*";
- Dividir as variáveis "*x*" e "*y*" em treino e teste usando a função "*train_test_split*", sendo 80% dos dados para treino e 20% para testes;
- Treinar o modelo escolhido (*Decision Tree*) com os dados de treino (*x_treino* e *y_treino*).

In [7]:
```
y = df['class']
x = df.drop('class', axis=1)
```

In [8]:
```
from sklearn.model_selection import train_test_split
```

In [9]:
```
x_treino, x_teste, y_treino, y_teste = train_test_split(x, y, test_size = 0.2)
```

Decision Tree Classifier

É um método de aprendizagem supervisionado não paramétrico usado para classificação e regressão. O objetivo é criar um modelo que preveja o valor de uma variável de destino, aprendendo regras de decisão simples inferidas dos recursos de dados. Uma árvore pode ser vista como uma aproximação constante por partes.

In [10]:
```
from sklearn.tree import DecisionTreeClassifier
```

In [11]:
```
modelo = DecisionTreeClassifier()
modelo.fit(x_treino, y_treino)
```

Out[11]:
```
DecisionTreeClassifier()
```

Imprimindo arvore de decisão

In [12]:
```
from sklearn import tree
clf = modelo.fit(x_treino, y_treino)
plt.figure(figsize=(10,10))  # set plot size (denoted in inches)
tree.plot_tree(clf, fontsize=8, feature_names=("sepal_length", "sepal_width", "petal_
plt.show()
```

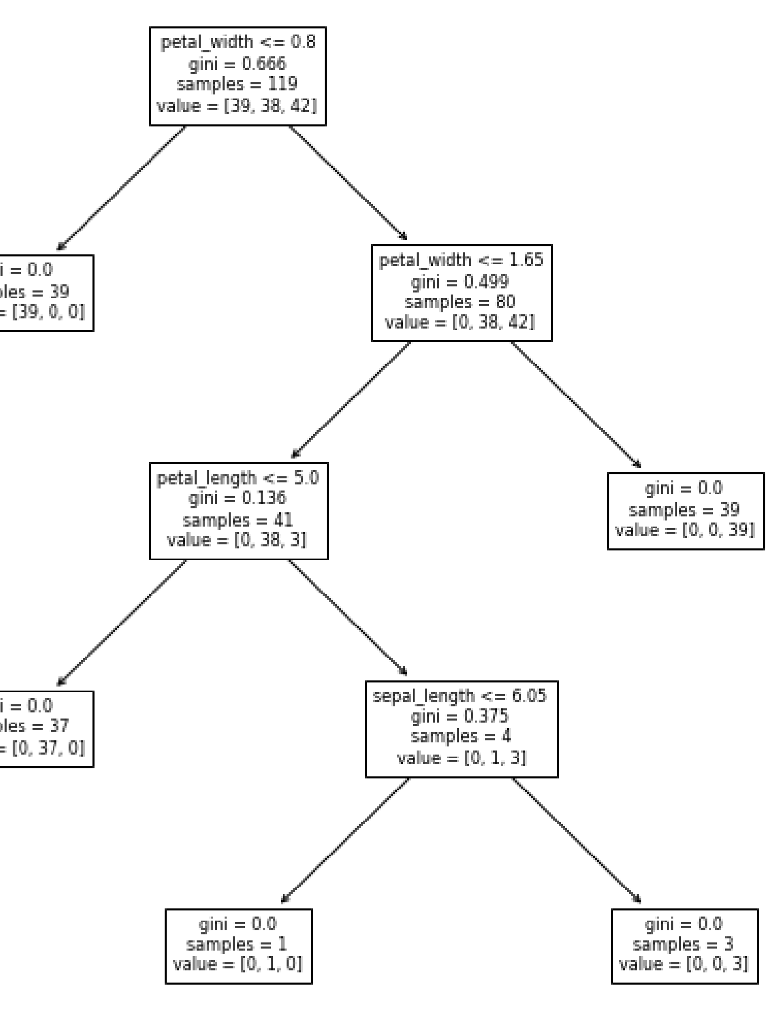

Após o treino, a acurácia obtida foi a que segue abaixo:

In [13]:
```
result = modelo.score(x_teste, y_teste)
print("Acurácia: ", result)
```

```
Acurácia:  0.9
```

Apicando agora os testes para denotar a previsão e repassá-la para a classificação, o resultado obtido foi o que segue abaixo, na tabela, onde pode-se observar os dados de *precision*, *recall*, *f1-score* e *support*:

In [14]:
```
previsoes = modelo.predict(x_teste)
```

In [15]:
```
previsoes
```

Out[15]:
```
array(['Iris-virginica', 'Iris-setosa', 'Iris-virginica',
       'Iris-versicolor', 'Iris-setosa', 'Iris-virginica',
       'Iris-virginica', 'Iris-setosa', 'Iris-versicolor',
       'Iris-versicolor', 'Iris-versicolor', 'Iris-setosa', 'Iris-setosa',
       'Iris-versicolor', 'Iris-setosa', 'Iris-virginica',
       'Iris-virginica', 'Iris-versicolor', 'Iris-versicolor',
       'Iris-versicolor', 'Iris-virginica', 'Iris-setosa', 'Iris-setosa',
       'Iris-setosa', 'Iris-virginica', 'Iris-versicolor',
       'Iris-virginica', 'Iris-versicolor', 'Iris-setosa',
       'Iris-versicolor'], dtype=object)
```

Classification Report

- TN / True Negative: o caso foi negativo e previsto como negativo
- TP / True Positive: o caso foi positivo e positivo previsto
- FN / False Negative: o caso era positivo, mas previsto como negativo
- FP / False Positive: o caso foi negativo, mas previsto como positivo

Precisão - Qual porcentagem de suas previsões estava correta?

É a capacidade de um classificador de não marcar uma instância como positiva (na verdade, negativa). Para cada categoria, é definido como a proporção de verdadeiros positivos para a soma de verdadeiros positivos e falsos positivos.

Formula (Precisão de previsões positivas): *Precision = TP/(TP + FP)*

Recall - Qual a porcentagem de casos positivos que você pegou?

É a capacidade do classificador de encontrar todas as instâncias positivas. Para cada categoria, é definido como a proporção de verdadeiros positivos para a soma de verdadeiros positivos e falsos negativos.

Fórmula (Fração de positivos que foram identificados corretamente): *Recall = TP/(TP+FN)*

F1 Score - Qual porcentagem de previsões positivas estavam corretas?

É a média harmônica ponderada de acurácia e recordação, portanto, a pontuação mais alta é 1,0 e a pior diferença é 0,0. As pontuações F1 são mais baixas do que as medições de precisão porque incorporam precisão e recall no cálculo. Geralmente, a média ponderada F1 deve ser usada para comparar os modelos do classificador, ao invés da precisão geral.

Fórmula: *F1 Score = 2*(Recall * Precision) / (Recall + Precision)*

Support

É o número real de ocorrências da classe no conjunto de dados especificado. O suporte desequilibrado nos dados de treinamento pode indicar fraquezas estruturais nas pontuações do classificador relatadas e pode indicar a necessidade de amostragem estratificada ou rebalanceamento. O suporte não mudará entre os modelos, mas sim um processo de avaliação diagnóstica.

In [16]:
```
from sklearn.metrics import classification_report, confusion_matrix, plot_confusion_ma
```

In [17]:
```
classification = classification_report(y_teste, previsoes)
print('-------------------CLASSIFICATION-----------------')
print(classification)
```

```
-------------------CLASSIFICATION-----------------
                 precision    recall  f1-score   support

    Iris-setosa       1.00      1.00      1.00        10
Iris-versicolor       0.91      0.83      0.87        12
 Iris-virginica       0.78      0.88      0.82         8

       accuracy                           0.90        30
      macro avg       0.90      0.90      0.90        30
   weighted avg       0.90      0.90      0.90        30
```

Matriz de Confusão

Por fim, foi feita a matriz de confusão de resultados, do conjunto de teste, que pode ser conferida abaixo na figura:

Uma matriz de confusão é uma tabela freqüentemente usada para descrever o desempenho de um modelo de classificação (ou classificador '') em um conjunto de dados de teste com valores verdadeiros conhecidos.

In [18]:
```
matrix = confusion_matrix(y_teste, previsoes)
```

In [19]:
```
plot_confusion_matrix(modelo, x_teste, y_teste)
plt.show()
```